

# Równania różniczkowe - spectral bias

**Zadanie 1.** Dane jest równanie różniczkowe zwyczajne

$$\frac{du(x)}{dx} = \cos(\omega x) \text{ dla } x \in \Omega, \quad (1)$$

gdzie:

$x, \omega, u \in \mathbb{R}$ ,

$x$  to położenie,

$\Omega$  to dziedzina, na której rozwiązujemy równanie,  $\Omega = \{x \mid -2\pi \leq x \leq 2\pi\}$ .

$u(\cdot)$  to funkcja, której postaci szukamy.

Warunek początkowy zdefiniowany jest następująco:

$$u(0) = 0. \quad (2)$$

Analityczna postać rozwiązania równania (1) z warunkiem początkowym (2) jest następująca:

$$u(x) = \frac{1}{\omega} \sin(\omega x). \quad (3)$$

Rozwiąż powyższe zagadnienie początkowe (1,2). Do rozwiązania użyj sieci neuronowych PINN (ang. *Physics-informed Neural Network*) [1]. Można wykorzystać szablon w `pytorch`-u lub bibliotekę `DeepXDE` [2].

Koszt rezydualny zdefiniowany jest następująco:

$$\mathcal{L}_r(\theta) = \frac{1}{N} \sum_{i=1}^N \left\| \frac{d\hat{u}(x)}{dx} - \cos(\omega x_i) \right\|^2, \quad (4)$$

gdzie  $N$  jest liczbą punktów kolokacyjnych.

Koszt związany z warunkiem początkowym przyjmuje postać:

$$\mathcal{L}_{IC}(\theta) = \|\hat{u}(0) - 0\|^2. \quad (5)$$

Funkcja kosztu zdefiniowana jest następująco:

$$\mathcal{L}(\theta) = \mathcal{L}_r(\theta) + \mathcal{L}_{IC}(\theta). \quad (6)$$

Warstwa wejściowa sieci posiada 1 neuron, reprezentujący zmienną  $x$ , Warstwa wyjściowa także posiada 1 neuron, reprezentujący zmienną  $\hat{u}(x)$ . Uczenie trwa przez 50 000 kroków algorytmem Adam ze stałą uczenia równą 0.001. Jako funkcję aktywacji przyjmij tangens hiperboliczny,  $\tanh$ .

(a) Przypadek  $\omega = 1$ .

Ustal następujące wartości:

- 2 warstwy ukryte, 16 neuronów w każdej warstwie
- liczba punktów treningowych: 200
- liczba punktów testowych: 1000

(b) Przypadek  $\omega = 15$ .

Ustal następujące wartości:

- liczba punktów treningowych:  $200 \cdot 15 = 3000$
- liczba punktów testowych: 5000

Eksperymenty przeprowadź z trzema architekturami sieci:

- 2 warstwy ukryte, 16 neuronów w każdej warstwie
- 4 warstwy ukryte, 64 neurony w każdej warstwie
- 5 warstw ukrytych, 128 neuronów w każdej warstwie

(c) Dla wybranej przez siebie sieci porównaj wynik z rozwiązaniem, w którym przyjęto, że szukane rozwiązanie (*ansatz*) ma postać:

$$\hat{u}(x; \theta) = \tanh(\omega x) \cdot NN(x; \theta). \quad (7)$$

Taka postać rozwiązania gwarantuje spełnienie warunku  $\hat{u}(0) = 0$  bez wprowadzania składnika  $\mathcal{L}_{IC}$  do funkcji kosztu.

(d) Porównaj pierwotny wynik z rozwiązaniem, w którym pierwszą warstwę ukrytą zainicjalizowano cechami Fouriera:

$$\gamma(x) = [\sin(2^0 \pi x), \cos(2^0 \pi x), \dots, \sin(2^{L-1} \pi x), \cos(2^{L-1} \pi x)]. \quad (8)$$

Dobierz  $L$  tak, aby nie zmieniać szerokości warstwy ukrytej.

Dla każdego z powyższych przypadków stwórz następujące wykresy:

- Wykres funkcji  $u(x)$ , tj. dokładnego rozwiązania oraz wykres funkcji  $\hat{u}(x)$ , tj. rozwiązania znalezionego przez sieć neuronową
- Wykres funkcji błędu.

Stwórz także wykres funkcji kosztu w zależności od liczby epok.

*Uwaga.* W przypadku wykorzystania biblioteki DeepXDE i backendu `tensorflow` należy użyć wersji tensorflow v1.

## Literatura

- [1] Raissi, M., Perdikaris, P., Karniadakis, G.E.: Physics Informed Deep Learning (Part I): Data-driven Solutions of Nonlinear Partial Differential Equations. CoRR **abs/1711.10561** (2017)
- [2] Lu Lu, Xuhui Meng, Zhiping Mao, George Em Karniadakis DeepXDE: A Deep Learning Library for Solving Differential Equations