

Laboratorium 11

June 19, 2024

1 Zadanie 1

1.1 $f(x, y) = x^2 - 4xy + y^2$

Pochodne cząstkowe tej funkcji wynoszą

$$\frac{\partial f}{\partial x} = 2x - 4y$$

$$\frac{\partial f}{\partial y} = 2y - 4x$$

Punkty krytyczne można znaleźć rozwiązując liniowy układ równań

$$\begin{bmatrix} 2 & -4 \\ -4 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

```
[1]: import numpy as np
```

```
[2]: A = np.array([[2, -4], [-4, 2]])  
b = np.array([0, 0])  
x, y = np.linalg.solve(A, b)  
print(f"x = {x}, y = {y}")
```

$x = -0.0, y = -0.0$

W wyniku czego otrzymujemy

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Macierz Hessego H wygląda następująco

$$H = \begin{bmatrix} 2 & -4 \\ -4 & 2 \end{bmatrix}$$

Minory tej macierzy mają następujące wyznaczniki

$$\begin{cases} H_1 = 2 \\ H_2 = 4 - 16 = -12 \end{cases}$$

Macierz jest nieokreślona, zatem punkt $(x, y) = (0, 0)$ jest punktem siodłowym.

Funkcja jest nieograniczona, zatem nie posiada minimum ani maksimum globalnego.

1.2 $f(x, y) = x^4 - 4xy + y^4$

Pochodne cząstkowe

$$\frac{\partial f}{\partial x} = 4x^3 - 4y$$

$$\frac{\partial f}{\partial y} = 4y^3 - 4x$$

Aby znaleźć punkty krytyczne należy rozwiązać nieliniowy układ równań

$$\begin{cases} 4x^3 - 4y = 0 \\ 4y^3 - 4x = 0 \end{cases}$$

```
[3]: import scipy.optimize as spo
```

```
[4]: def fprime(args):
    x = args[0]
    y = args[1]
    return [
        4*x**3 - 4*y,
        4*y**3 - 4*x
    ]
```

Potencjalne rozwiązania układu można łatwo oszacować analitycznie.

```
[5]: x1, y1 = spo.fsolve(fprime, (0, 0))
    x2, y2 = spo.fsolve(fprime, (1, 1))
    x3, y3 = spo.fsolve(fprime, (-1, -1))
```

```
[6]: print(f"(x1, y1) = ({x1}, {y1}), (x2, y2) = ({x2}, {y2}), (x3, y3) = ({x3}, {y3})")
```

(x1, y1) = (0.0, 0.0), (x2, y2) = (1.0, 1.0), (x3, y3) = (-1.0, -1.0)

Otrzymaliśmy 3 punkty krytyczne

$$\begin{cases} P_1 = (0, 0) \\ P_2 = (1, 1) \\ P_3 = (-1, -1) \end{cases}$$

Macierz Hessego

$$H(x, y) = \begin{bmatrix} 12x^2 & -4 \\ -4 & 12y^2 \end{bmatrix}$$

```
[7]: def make_hessian(P):
    x = P[0]
    y = P[1]
    return np.array([
        [12*x**2, -4],
        [-4, 12*y**2]
```

```
)
```

```
[8]: P1 = (x1, y1)
      P2 = (x2, y2)
      P3 = (x3, y3)
```

```
[9]: H1 = make_hessian(P1)
      try:
          np.linalg.cholesky(H1)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is NOT positive definite!

Macierz nie jest dodatnio określona, niestety trzeba teraz ręcznie sprawdzić, czy jest ujemnie określona

$$H(0,0) = \begin{bmatrix} 0 & -4 \\ -4 & 0 \end{bmatrix}$$

$$\begin{cases} H_1 = 0 \\ H_2 = -16 \end{cases}$$

Macierz jest nieokreślona, zatem punkt $(0,0)$ jest punktem siodłowym.

```
[10]: H2 = make_hessian(P2)
      try:
          np.linalg.cholesky(H2)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is positive definite!

Macierz $H(1,1)$ jest dodatnio określona, zatem w punkcie $(1,1)$ funkcja przyjmuje minimum.

```
[11]: H3 = make_hessian(P3)
      try:
          np.linalg.cholesky(H3)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is positive definite!

Macierz $H(1,1)$ również jest dodatnio określona, zatem w punkcie $(1,1)$ funkcja przyjmuje minimum.

```
[12]: f = lambda x, y: x**4 - 4*x*y + y**4
      val2 = f(x2, y2)
      val3 = f(x3, y3)
      print(val2, val3)
```

-2.0 -2.0

Funkcja przyjmuje takie same wartości w punktach P_1 i P_2 , punkty te są minimami globalnymi

$$1.3 \quad f(x, y) = 2x^3 - 3x^2 - 6xy(x - y - 1)$$

Pochodne cząstkowe wynoszą

$$\frac{\partial f}{\partial x} = 6(x^2 - 2xy - x + y^2 + y)$$

$$\frac{\partial f}{\partial y} = -6x(x - 2y - 1)$$

$$\begin{cases} x^2 - 2xy - x + y^2 + y = 0 \\ x^2 - 2yx - x = 0 \end{cases}$$

```
[13]: def fprime(P):
      x = P[0]
      y = P[1]
      return [
          x**2 - 2*x*y - x + y**2 + y,
          x**2 - 2*x*y - x
      ]
```

```
[14]: solution_set = set()
      for x in range(-1, 2):
          for y in range(-1, 2):
              sol_x, sol_y = spo.fsolve(fprime, (x, y))
              solution_set.add((round(sol_x, 5), round(sol_y, 5)))
      print(*solution_set, sep="\n")
```

(1.0, 0.0)
(0.0, -1.0)
(-1.0, -1.0)
(0.0, 0.0)

Funkcja ma 4 punkty krytyczne

$$\begin{cases} P_1 = (-1, -1) \\ P_2 = (0, 0) \\ P_3 = (1, 0) \\ P_4 = (0, -1) \end{cases}$$

Macierz Hessego

$$H(x,y) = \begin{bmatrix} 12x - 12y - 6 & -6(x - y - 1) - 6x + 6y \\ -6(x - y - 1) - 6x + 6y & 12x \end{bmatrix}$$

```
[15]: def make_hessian(P):  
      x = P[0]  
      y = P[1]  
      return np.array([  
          12*x-12*y-6, -6*(x-y-1) - 6*x + 6*y],  
          [-6*(x-y-1) - 6*x + 6*y, 12*x]  
      ])
```

```
[16]: # returns 1 if negative definite, -1 if semi definite and 0 if indefinite  
def check_negative_definite(H):  
    flag = True  
    if H[0][0] > 0:  
        return 0  
    elif H[0][0] == 0:  
        flag = False  
  
    det = np.linalg.det(H)  
    if det < 0:  
        return 0  
    elif det == 0:  
        flag = False  
  
    return 1 if flag else -1
```

```
[17]: H1 = make_hessian((-1, -1))  
try:  
    np.linalg.cholesky(H1)  
except np.linalg.LinAlgError:  
    print("H1 is NOT positive definite!")  
else:  
    print("H1 is positive definite!")
```

H1 is NOT positive definite!

Macierz nie jest dodatnio określona, trzeba ją sprawdzić ręcznie.

```
[18]: check_negative_definite(H1)
```

```
[18]: 1
```

Funkcja zwróciła 1, co oznacza, że macierz jest ujemnie określona, zatem w punkcie $(-1, -1)$ występuje maksimum.

```
[19]: H2 = make_hessian((0, 0))
      try:
          np.linalg.cholesky(H2)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is NOT positive definite!

```
[20]: check_negative_definite(H2)
```

```
[20]: 0
```

Macierz jest nieokreślona, co oznacza, że punkt (0,0) jest punktem siodłowym.

```
[21]: H3 = make_hessian((1, 0))
      try:
          np.linalg.cholesky(H3)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is positive definite!

Macierz jest dodatnio określona, w punkcie (1,0) jest minimum.

```
[22]: H4 = make_hessian((0, -1))
      try:
          np.linalg.cholesky(H4)
      except np.linalg.LinAlgError:
          print("H1 is NOT positive definite!")
      else:
          print("H1 is positive definite!")
```

H1 is NOT positive definite!

```
[23]: check_negative_definite(H4)
```

```
[23]: 0
```

Macierz jest nieokreślona, punkt (0, -1) jest punktem siodłowym

Funkcja nie posiada maksimum ani minimum globalnego.

$$1.4 \quad f(x, y) = (x - y)^4 + x^2 - y^2 - 2x + 2y + 1$$

$$\frac{\partial f}{\partial x} = 4(x - y)^3 + 2x - 1$$

$$\frac{\partial f}{\partial y} = -4(x - y)^3 - 2y + 2$$

```
[24]: def fprime(P):
      x = P[0]
      y = P[1]
      return [
          4*(x-y)**3 + 2*x - 1,
          -4*(x-y)**3 - 2*y + 2
      ]
```

```
[25]: solution_set = set()
      for x in range(-2, 3):
          for y in range(-2, 3):
              sol_x, sol_y = spo.fsolve(fprime, (x, y))
              solution_set.add((round(sol_x, 5), round(sol_y, 5)))
      print(*solution_set, sep="\n")
```

(0.75, 1.25)

Funkcja ma tylko 1 punkt krytyczny $P = (0.75, 1.25)$

Macierz Hessego dla punktu P

$$H = \begin{bmatrix} 5 & -3 \\ -3 & 1 \end{bmatrix}$$

$$\begin{cases} H_1 = 5 \\ H_2 = 5 - 9 = -4 \end{cases}$$

Macierz jest nieokreślona, punkt $(0.75, 1.25)$ jest punktem siodłowym, funkcja nie ma minimum ani maksimum globalnego.

2 Zadanie 2

$$F(\mathbf{x}) = \lambda_1 \sum_{i=0}^n \sum_{j=0}^{k-1} \frac{1}{\epsilon + \|x_i - r_j\|_2^2} + \lambda_2 \sum_{i=0}^{n-1} \|x_{i+1} - x_i\|_2^2$$

$$F : \mathbb{R}^{n \times 2} \rightarrow \mathbb{R}$$

Funkcja największego spadku dla \mathbf{x} .

$$\nabla F(\mathbf{x}) = \frac{\partial F}{\partial \mathbf{x}} = -\lambda_1 \sum_{j=0}^{k-1} \left[\frac{2(x_i - r_j)}{(\epsilon + \|x_i - r_j\|_2^2)^2} \right] + \lambda_2 (-2(x_{i+1} - x_i) + 2(x_i - x_{i-1}))$$

$$\nabla F : \mathbb{R}^{n \times 2} \rightarrow \mathbb{R}^{n \times 2}$$

Algorytm najmniejszego spadku wykorzystuje początkowe ustawienie punktów \mathbf{x}_0 , następnie na ich podstawie wyliczane są następne ustawienia, dla których funkcja osiąga coraz mniejsze wartości.

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla F(\mathbf{x}_k)$$

Gdzie α szukane jest poprzez minimalizację

$$\min_{\alpha} F(\mathbf{x}_k - \alpha \nabla F(\mathbf{x}_k))$$

Minimalizacja jest minimalizacją jednej zmiennej α , więc można zastosować algorytm *golden section search*.

Do minimalizacji *golden section search* jako przedział podstawowy został wybrany przedział $[0, 441]$, ze względu na wymiary planszy robota 21×21

```
[26]: import random
      from copy import deepcopy
      import matplotlib.pyplot as plt
```

```
[27]: def F(x, r):
      lambda1 = lambda2 = 1
      n = len(x)
      k = len(r)
      epsilon = 1e-13

      res1 = 0
      for i in range(n):
          for j in range(k):
              res1 += 1 / (epsilon + np.linalg.norm(x[i] - r[j])**2)

      res1 *= lambda1

      res2 = 0
      for i in range(n-1):
          res2 += np.linalg.norm(x[i+1] - x[i])**2

      res2 *= lambda2

      return res1 + res2

def gradient(x, r):
    lambda1 = lambda2 = 1
    n = len(x)
    k = len(r)
    epsilon = 1e-13

    res = [None for _ in range(n)]
    for i in range(1, n-1):
        res[i] = -lambda1 * np.sum([(2 * (x[i] - r[j])) / (epsilon + np.linalg.
↪norm(x[i] - r[j])**2)**2 for j in range(k)], axis=0) + lambda2*(-2*(x[i+1] -
↪x[i]) + 2*(x[i] - x[i] - 1))

    res[0] = np.array([0, 0])
```



```
res[-1] = np.array([0, 0])
return np.array(res)
```

```
[28]: def golden_search(f, x, r):
    a = 0
    b = 441
    t = (np.sqrt(5)-1) / 2
    x1 = a + (1 - t) * (b - a)
    f1 = f(x1, x, r)
    x2 = a + t*(b-a)
    f2 = f(x2, x, r)
    tol = 1e-5
    while (b-a) > tol:
        if f1 > f2:
            a = x1
            x1 = x2
            f1 = f2
            x2 = a + t*(b-a)
            f2 = f(x2, x, r)
        else:
            b = x2
            x2 = x1
            f2 = f1
            x1 = a + (1 - t) * (b - a)
            f1 = f(x1, x, r)

    return (a+b)/2

def F_min(alfa, x0, r):
    return F(x0 - alfa * gradient(x0, r), r)

def minimize(x, r):
    x0 = deepcopy(x)
    for _ in range(400):
        alfa = golden_search(F_min, x0, r)
        x0 = x0 - alfa * gradient(x0, r)
    return x0
```

```
[29]: rng = random.Random(2137)
```

2.1 Próba 1

```
[30]: points = [np.array([rng.randrange(0, 21), rng.randrange(0,21)]) for _ in
    ↪range(21)]
points[0] = np.array([0, 0])
points[-1] = np.array([20, 20])
```

```


obstacles = [np.array([rng.randrange(1, 20), rng.randrange(1, 20)]) for _ in
↪range(50)]
points_xs = [points[i][0] for i in range(21)]
points_ys = [points[i][1] for i in range(21)]
obstacles_xs = [obstacles[i][0] for i in range(50)]
obstacles_ys = [obstacles[i][1] for i in range(50)]

```

```

[31]: plt.scatter(points_xs, points_ys, color="blue", label="points")
      plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
      plt.legend()
      plt.show()

```



```

[32]: shortest = minimize(points, obstacles)

```

```

[33]: print(f"Function result: {F(points, obstacles)}")

```


Function result: 40000000004863.68

```

[34]: shortest_xs = [shortest[i][0] for i in range(21)]
      shortest_ys = [shortest[i][1] for i in range(21)]

```


```
[35]: plt.scatter(shortest_xs, shortest_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```



2.2 Próba 2

```
[36]: points = [np.array([rng.randrange(0, 21), rng.randrange(0,21)]) for _ in
↳range(21)]
points[0] = np.array([0, 0])
points[-1] = np.array([20, 20])
obstacles = [np.array([rng.randrange(1, 20), rng.randrange(1, 20)]) for _ in
↳range(50)]
points_xs = [points[i][0] for i in range(21)]
points_ys = [points[i][1] for i in range(21)]
obstacles_xs = [obstacles[i][0] for i in range(50)]
obstacles_ys = [obstacles[i][1] for i in range(50)]
```

```
[37]: plt.scatter(points_xs, points_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```




```
[38]: shortest = minimize(points, obstacles)
```

```
[39]: print(f"Function result: {F(points, obstacles)}")
```

Function result: 2540.1306437524804

```
[40]: shortest_xs = [shortest[i][0] for i in range(21)]
shortest_ys = [shortest[i][1] for i in range(21)]
```


```
[41]: plt.scatter(shortest_xs, shortest_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```



2.3 Próba 3

```
[42]: points = [np.array([rng.randrange(0, 21), rng.randrange(0,21)]) for _ in
↳range(21)]
points[0] = np.array([0, 0])
points[-1] = np.array([20, 20])
obstacles = [np.array([rng.randrange(1, 20), rng.randrange(1, 20)]) for _ in
↳range(50)]
points_xs = [points[i][0] for i in range(21)]
points_ys = [points[i][1] for i in range(21)]
obstacles_xs = [obstacles[i][0] for i in range(50)]
obstacles_ys = [obstacles[i][1] for i in range(50)]
```

```
[43]: plt.scatter(points_xs, points_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```




```
[44]: shortest = minimize(points, obstacles)
```

```
[45]: print(f"Function result: {F(points, obstacles)}")
```

Function result: 20000000003079.777

```
[46]: shortest_xs = [shortest[i][0] for i in range(21)]
shortest_ys = [shortest[i][1] for i in range(21)]
```


```
[47]: plt.scatter(shortest_xs, shortest_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```



2.4 Próba 4

```
[48]: points = [np.array([rng.randrange(0, 21), rng.randrange(0,21)]) for _ in
↳range(21)]
points[0] = np.array([0, 0])
points[-1] = np.array([20, 20])
obstacles = [np.array([rng.randrange(1, 20), rng.randrange(1, 20)]) for _ in
↳range(50)]
points_xs = [points[i][0] for i in range(21)]
points_ys = [points[i][1] for i in range(21)]
obstacles_xs = [obstacles[i][0] for i in range(50)]
obstacles_ys = [obstacles[i][1] for i in range(50)]
```

```
[49]: plt.scatter(points_xs, points_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```




```
[50]: shortest = minimize(points, obstacles)
```

```
[51]: print(f"Function result: {F(points, obstacles)}")
```

Function result: 30000000003386.863

```
[52]: shortest_xs = [shortest[i][0] for i in range(21)]
shortest_ys = [shortest[i][1] for i in range(21)]
```


```
[53]: plt.scatter(shortest_xs, shortest_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```

2.5 Próba 5

```
[54]: points = [np.array([rng.randrange(0, 21), rng.randrange(0,21)]) for _ in
↳range(21)]
points[0] = np.array([0, 0])
points[-1] = np.array([20, 20])
obstacles = [np.array([rng.randrange(1, 20), rng.randrange(1, 20)]) for _ in
↳range(50)]
points_xs = [points[i][0] for i in range(21)]
points_ys = [points[i][1] for i in range(21)]
obstacles_xs = [obstacles[i][0] for i in range(50)]
obstacles_ys = [obstacles[i][1] for i in range(50)]
```

```
[55]: plt.scatter(points_xs, points_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```




```
[56]: shortest = minimize(points, obstacles)
```

```
[57]: print(f"Function result: {F(points, obstacles)}")
```

Function result: 30000000002305.12

```
[58]: shortest_xs = [shortest[i][0] for i in range(21)]
shortest_ys = [shortest[i][1] for i in range(21)]
```

```
[59]: plt.scatter(shortest_xs, shortest_ys, color="blue", label="points")
plt.scatter(obstacles_xs, obstacles_ys, color="red", label="obstacles")
plt.legend()
plt.show()
```



2.6 Wnioski

Można zauważyć pewną prawidłowość w wyliczaniu ścieżki robota. Pierwszy przystanek jest w znacznej odległości od pola startowego. Wszystkie pozostałe przystanki są znacznie bliżej siebie.